

Research on Property Value Prediction Mechanisms and Market Classification Based on POI Feature Fusion

《POI 特征融合下的的房产价值预测机制与市场分类研究》

231820307 吴林洁; 231820309 罗一逖

摘要——随着地理信息系统和大数据技术的发展, 将环境特征引入房价预测已经成为新的研究热点。本研究构建了一个融合 POI (Point of interest) 特征的房产价值预测与市场分类框架。基于北京市 2011-2012 年 9477 条有效房源交易数据和 POI 数据, 构建 POI 显著性指标量化周围环境对房价的影响, 从建筑硬件、空间区位和房屋属性三个方面构建特征体系, 并采用岭回归、Lasso 回归、弹性网络、随机森林、梯度提升树、XGBoost、LightGBM、支持向量机和多层感知器九种机器学习方法构建房价预测模型并对比分析。结果表明, 集成学习方法在预测精度上优于相信模型, 其中随机森林模型 R^2 达 0.729, 表现出较高的解释力和稳健性。进一步利用网络分析和空间聚类算法, 将北京市划分为六个房产子市场, 发现医疗、商业和教育资源的集聚是形成房价空间分类的重要影响因素。研究验证了融合 POI 数据进行房产分析的可行性和有效性, 为城市规划、房产市场分类及房地产战略决策提供了科学的理论和数据支撑。

关键词——POI; 房产价值; 机器学习; 网络分析; 空间聚类; 市场分类

1. 引言

2025 年 10 月 24 日, 二十届中央委员会第四次全体会议高度重视房地产行业, 公报表示“加大保障和改善民生力度, 推动房地产行业高质量发展”。^[1] 房价高低成为关系到民生切身利益的重大经济问题和社会问题。然而, 房地产市场跌宕起伏, 关于房价的波动分析和研究一直是学术

界关注的热点话题。

房价波动受到错综复杂的影响, 大量研究集中关注房产数量、建筑面积、户型结构等基础房产信息^[2], 但周围的设施、交通状况、教育资源等潜在环境特征受到的关注相对有限。近年来随着地理信息系统和大数据技术的发展, 部分学者开始将 POI (Point of interest) 数据引入房价研究。Tang, J.^[3] 结合 POI 的核密度值构建用于估算缺失房价的数据融合模型; Liu, X.^[4] 探索了 POI 显著性、社交媒体数据等对房价的影响; Shen, H.^[5] 提出基于卷积神经网络和 POI 合成空间密度的定价模型。为进一步研究提供了新的路径。

目前研究采用了很多方法预测房价。李贤增^[6] 基于线性模型和非线性模型进行房价预测; 谷秀娟^[7] 基于马尔科夫链构建房价预测模型; 唐晓彬^[8] 将蝙蝠算法引入 SVR 模型, 结合网格搜索构建房价预测模型; 秦艳姣^[9] 使用多元线性回归和随机森林两种机器学习算法构建预测模型并对比结果; Singh, A.^[10] 使用线性回归、随机森林回归和决策树回归预测房价。可见, 很多研究都使用单一或者少量机器学习算法。

基于上述背景, 本研究提出 POI 显著性指标, 基于融合 POI 数据构建一系列机器学习模型进行房价预测, 并从四个维度进行模型对比。在构建机器学习预测模型的基础上, 利用 POI 与房产之间的空间关联构建复杂网络模型, 并结合聚类分析探索城市内的房价市场划分。

2. 方法

本研究构建了一个融合 POI 特征的房产价值预测与市场分类框架，该框架包含四个核心环节：首先，基于北京市链家房地产公司 2011-2012 年交易的 10000 条房源数据，提取地理信息并爬取 POI 特征；其次，构建 POI 显著性指标；然后，结合 POI 显著性指标、建筑硬件指标和户型指标三个维度，采用多种机器学习算法构建房产价值预测模型并进行性能评估；最后，结合网络分析和聚类分析对房地产市场进行划分。该方法框架旨在通过融合 POI 后的房产特征，实现对房产价值的准确预测和对房产市场的精细划分，为房地产研究和市场决策提供科学依据。

2.1 数据准备

本研究使用的北京市链家房地产公司 2011-2012 年交易的 10000 条房源数据来源于公开数据集，经过数据清洗最终得到 9477 条有用数据。根据房产经纬度坐标，从 OpenStreetMap 平台爬取其周边兴趣点 (POI) 数据，为房价预测与空间分析提供了基础数据。最后，利用 POI 数据对房源进行聚类分析，将房产周围环境分为 11 类：amenity, shop, tourism, leisure, healthcare, public_transport, railway, aeroway, sport, education, office。

2.2 POI 显著性指标构建

在房价预测中，周围配套设施 (POI, Point of Interest) 对房产价值的预测具有重要影响。为了更清晰地展现 POI 的潜在贡献，本文构建了一个可量化的 POI 显著性指标，既考虑数据驱动，又结合实际常理。

2.2.1 计算 POI 原始分数

各类别 POI 的作用遵循距离衰减效应，越近的 POI 对房产价值的贡献率越高。据此，定义 POI 原始分数为：

$$score_{i,j}^{raw} = \sum_{k \in POI_j} e^{-\alpha \cdot dist(i,k)}, \text{if } dist(i,k) \leq D_{max} \quad (1)$$

其中：

- j 表示 POI 类别
- $dist(i,k)$ 为房源 i 到 POI_k 的地理距离 (单位：公里)
- α 为距离衰减系数，设置为 0.5
- D_{max} 为最大考虑距离，设置为 1 公里

2.2.2 计算权重

采用人工设置先验权重，结合数据驱动动态加权的方式确定权重。在前期实验中，仅使用数据驱动加权可能出现异常情况，比如显然比较重要的“education”类权重仅为 0.01。此外，由于经验的缺乏性，仅仅使用人工赋权具有主观性。因此，定义全局 POI 权重为先验权重与数据驱动权重的平均值。

根据经验和常识，确定先验权重如下：

表 1
先验权重表

POI 类别	先验权重
amenity	0.8
shop	0.7
tourism	0.6
leisure	0.6
healthcare	1.0
Public_transport	1.0
railway	0.8
aeroway	0.3
sport	0.5
education	1.0
office	0.6

数据驱动权重结合 POI 数量与房价的绝对相关性 $|corr(S_j, price)|$ 和随机森林回归特征重要性 RF_j 计算，公式为：

$$w_j^{(data)} = \frac{|corr(S_j, price)| + RF_j}{2} \quad (2)$$

最终，全局 POI 权重计算公式为：

$$w_j = \alpha_{prior} * w_j^{(prior)} + \alpha_{data} * w_j^{(data)}, \alpha_{prior} = \alpha_{data} = 0.5 \quad (3)$$

2.2.3 计算 POI 显著性指标

对于每个房源数据，将各类别进行归一化处理，再进行权重求和，得到最终 POI 显著性指标为：

$$POI_score_i = \sum_j \frac{S_{ij}^{(raw)}}{\sum_j S_{ij}^{(raw)}} * w_j \quad (4)$$

2.3 房产价值预测模型构建

2.3.1 构建房价预测特征体系

本研究构建了系统化的房价预测特征体系，包括建筑硬件方面、空间区位方面和房屋属性方面。

在建筑硬件方面，原始特征包括建筑结构、电梯、楼层、房屋朝向和梯户比五个核心特征。除了梯户比其余都是文本变量，采用常识和经验赋值的方式，将建筑结构、朝向进行打分，同时联合电梯与楼层打分得到电梯楼层组合特征，得到四个核心特征。接着，通过相关性分析、随机森林特征重要性双重机制确定四个特征的权重分配，得到建筑硬件总分数。表 2-4 展现了人工赋权的结果。

表 2
建筑结构人工赋权表

特征取值	得分	说明
钢混结构	0.95	稳定性最佳、抗震性更好
混合结构	0.75	稳定性较好
砖混结构	0.45	稳定性一般
砖木结构	0.25	稳定性较差
其他/未知	0.50	/

表 3
电梯楼层组合人工赋权表

特征取值	得分	说明
有电梯 + 中/高楼层/顶层	1.00	电梯便利性与视野采光最佳组合
有电梯 + 低楼层/底层	0.70	有电梯但楼层较低便利性稍差
无电梯 + 底层/低楼层	0.80	无电梯但楼层低步行便利
无电梯 + 中楼层	0.50	无电梯中等楼层步行一般
无电梯 + 高楼层/顶层	0.30	无电梯高楼层步行不便
其他情况	0.50	/

表 4
房屋朝向人工赋权表

特征取值	得分	说明
南北通透	0.95	通风采光最佳, 市场最受欢迎
纯南向	0.75	采光好但通风稍差
其他朝向	0.40	采光通风相对较差
其他情况	0.25	/

在空间区位方面，除了 2.2 提到的 POI 显著性指标，还将卧室数量、面积与 POI 交互得到交互特征，捕捉区位与房屋属性的协同效应，也避免了与面积直接接触产生的数据泄露问题。

在房屋属性方面，包含卧室、卫生间、客厅、厨房等基础属性，也衍生出单个房间的面积特征，更全面的描述房屋的空间利用情况。

整个特征体系采用异常值处理、缺失值处理、分层抽样等方式保障了数据的可靠性和稳定性。

2.3.2 模型选择与评估方法

本研究选择岭回归、Lasso 回归、弹性网络、随机森林、梯度提升树、XGBoost、LightGBM、支持向量机和多层感知器共九种机器学习算法进行房价预测建模。模型选择：考虑到数据集的特点，选择经过充分验证且表现相对稳定的经典机器学习模型，避免过于复杂的架构产生过拟合问题；其次，也有效平衡了训练效率和预测精度之间的关系；最后，从线性模型到集成方法再到高维空间方法及多层感知器架构，能够提供更加多样化的视角，从而验证结果的稳健性。此外，使用了网格搜索进行超参数调优，通过 5 折交叉验证选择最佳参数组合。表 5 展示了各模型在超参数调优过程中的关键参数配置：

表 5
关键参数配置

模型名称	关键参数	参数含义说明	参数取值范围
岭回归	alpha	L2 正则化强度	[0.1, 1.0, 10.0, 100.0]
Lasso 回归	alpha	L1 正则化强度	[0.001, 0.01, 0.1, 1.0]
弹性网络	alpha l1_ratio	总体正则化强度	[0.01, 0.1, 1.0] [0.2, 0.5, 0.8]
随机森林	n_estimators max_depth min_samples_split min_samples_leaf	树的数量 树的最大深度 内部节点分裂最小样本数 叶节点最小样本数	[100, 200, 300] [10, 15, 20, None] [2, 5, 10] [1, 2, 4]
梯度提升树	n_estimators learning_rate max_depth subsample	弱学习器数量 学习率 树的最大深度 样本采样比例	[100, 200, 300] [0.05, 0.1, 0.15] [3, 5, 7] [0.8, 0.9, 1.0]

XGBoost	n_estimators max_depth learning_rate subsample colsample_bytree	树的数量 树的最大深度 学习率 样本采样比例 特征采样比例	[100, 200, 300] [6, 8, 10] [0.05, 0.1, 0.15] [0.8, 0.9, 1.0] [0.8, 0.9, 1.0]
LightGBM	n_estimators max_depth learning_rate num_leaves subsample	树的数量 树的最大深度 (-1 表示无限制) 学习率 叶节点数量 样本采样比例	[100, 200, 300] [6, 8, 10, -1] [0.05, 0.1, 0.15] [31, 63, 127] [0.8, 0.9, 1.0]
支持向量机回归	C kernel gamma	惩罚系数 核函数类型 核函数系数	[0.1, 1.0, 10.0, 100.0] ['rbf', 'linear'] ['scale', 'auto']
多层感知器	hidden_layer_sizes alpha learning_rate early_stopping	隐藏层结构 L2 正则化系数 学习率策略 早停法启用	[(50,), (100,), (50,50), (100,50)] [0.0001, 0.001, 0.01] ['constant', 'adaptive'] [True]

本研究按照 8:2 比例划分训练集和测试集，采用分层抽样确保数据的一致性。采用 5 折交叉验证提供模型稳定性的可靠估计。

模型评估采用多维度评价指标体系，包括决定系数 (R^2)、均方根误差 (RMSE)、平均绝对误差 (MAE) 和平均绝对百分比误差 (MAPE)。决定系数反映模型对房价变动的解释能力，均方根误差用于衡量预测值与实际值的平均偏差程度，平均绝对误差反映预测误差的绝对水平，平均绝对百分比误差提供误差相对于实际价格的百分比视角，便于直观理解预测精度。

2.4 市场划分模型构建

在前文模型构建的基础上，本文将训练得到的模型映射到空间层面，从整体城市的层面分析房产价格分布的空间特征。所有 POI 兴趣点和房产分布的地理分布特征，如下图 1 所示：

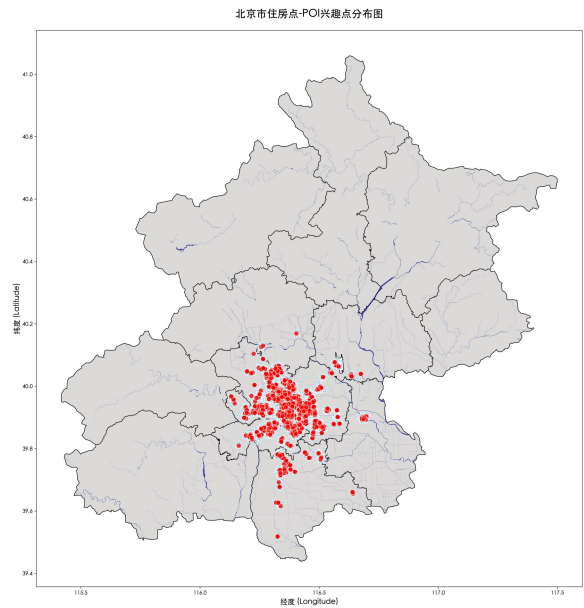


图 1. POI 兴趣点与房产点地理分布图

从图 1 中可以看到，所有房产交易数据都集中在北京的中心城区，边缘县城的交易数据量极少，此外，也能发现，所有房产交易大多都是集群出现，孤立的房产交易点极少。因而，我们可以据此缩小研究的范围，将研究的地域缩小到北京的中心城区，更深入的观察中心城区的价格分布特征，如下图 2 所示：

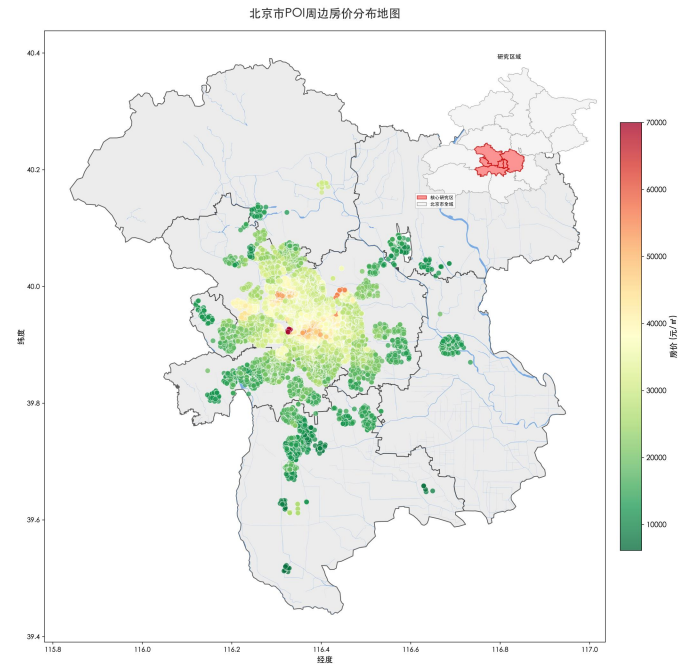


图 2. POI 周边房产价格地理分布图

从图 2 中可以直观看到北京城区的房价分布特征，不

难发现，越靠近中心城区的位置，房产的价格会越高，而越远离中心城区，则房产价格越低。这基本符合人们的直观认知。不过，也能看到，也有不少远离中心点的房产呈现高房价特征，并形成价格集群。这说明，在北京市内，存在多个不同的房价市场，这为市场划分模型的构建提供了现实可能。

基于此，本研究将从网络分析的视角，用网络结构对房价市场进行划分。具体而言，若 POI 点与房产点之间距离小于 1km，则形成边连接，如此，最终形成一个包含 2752477 条边的复杂网络模型，该网络经过 OpenOrd 开源算法可视化后的图如下图 3 所示：




图 3. POI 点与住房点网络图

不难发现，绝大多数点之间都是相互连接，只有少数点与整体图距离过远，无法连接。因而，本研究将主要聚焦于主连通图，对应于北京中心城区的住房环境，以此探索北京中心房产的价格分布空间。

本研究认为，房价市场区分的核心点在于影响房产价格核心因素的变化，核心因素在很大程度上决定了该市场的性质和风向。因而，本研究将房价市场的主要影响因素作为聚类的核心参考指标，以此划分房价市场的变动区间。同时，作为城市房价市场的分类，也应当考虑城市的空间因素指标，确保市场划分的连续性。本研究采用了 SKATER 空间分布算法，结合每个房产点的地理分布特征和房产价格影响因素进行聚类。

为了减少算法复杂度，在聚类过程中选择前文机器学习模型中得到的影响因素较大的因子作为聚类因子，作为影响房价市场的主导因素。例如，在房产的内部因素中，建筑结构，梯户密度等重要性权值较大，将其作为聚类的因素；POI 数据中，交通中心、购物中心等的影响较大，所以将是否具有交通中心等作为聚类要素。此外，添加房产节点在网络中的接近中心性，节点距离市中心距离等指标。最终，在综合高密度因素的情况下，以房产价格为最终目标，达到最终的聚类结果。

3. 实证结果与分析

3.1 房产价值模型预测结果

3.1.1 权重的最终确定

通过相关性分析、随机森林特征重要性双重机制确定最终的 POI 及建筑硬件全局权重如下：

表 6
POI 全局权重

类别	权重
amenity	0.5583
shop	0.4693
tourism	0.4517
leisure	0.4182
healthcare	0.5753
public_transport	0.6301
railway	0.4549
aeroway	0.1587
sport	0.2545
education	0.5000
office	0.5235

表 7
建筑硬件全局权重

特征	权重
梯户比密度	0.317
建筑结构	0.249
房屋朝向	0.235
电梯楼层组合	0.199

3.1.2 模型对比分析

本研究采用九种机器学习算法构建房价预测模型，建立了以决定系数为核心，结合均方根误差、平均绝对误差和平均绝对百分比误差的多维评估体系，通过 5 折交叉验证确保模型泛化能力。实验结果显示，随机森林 (RandomForest) 表现最佳， R^2 达到 72.92%，RMSE 为 5206.74 元/平方米，MAE 为 3412.02 元/平方米，MAPE 为 15.0%；梯度提升树 (GradientBoosting) 和 XGBoost 紧随其后， R^2 分别为 71.95% 和 72.45%；LightGBM 位列第四， R^2 为 69.55%。相比之下，传统线性模型表现最差，岭回归、Lasso 回归和弹性网络 (ElasticNet) 的 R^2 均不足 3%。

表 8
房价预测模型性能对比结果

模 型 名 称	R^2	RMSE	MAE	MAP E	交叉验证 R^2 均值	交叉验证 R^2 标准差
岭 回 归	0.0287	9860.26	7951.21	37.2	0.0283	0.0084
Lasso 回 归	0.0283	9862.74	7956.58	37.1	0.0280	0.0085
弹 性 网 络	0.0288	9860.02	7950.35	37.2	0.0285	0.0084
随 机 森 林	0.7292	5206.74	3412.02	15.0	0.7285	0.0123
梯 度 提 升 树	0.7195	5298.55	3535.69	15.6	0.7190	0.0118
XGB oost	0.7245	5251.65	3500.13	15.5	0.7240	0.0121
Light GBM	0.6955	5521.20	3688.06	16.3	0.6950	0.0135
SVR	0.0919	9534.51	7450.14	32.6	0.0915	0.0102
MLP	0.1549	9197.77	7300.37	33.1	0.1540	0.0156




图 4. 模型性能对比图

基于树模型的集成学习方法（随机森林、XGBoost、梯度提升树、LightGBM）的 R^2 均超过 69%，而传统线性模型表现明显较差，这一结果表明房价预测是一个复杂非线性任务。结合特征体系分析，房价受到建筑硬件特征、空间区位特征和房屋属性特征三大类特征的共同影响，这些变量间存在复杂的非线性交互关系，超出了传统线性模型的表征能力。随机森林模型的良好表现说明构建该预测体系的有效性，1.23%的交叉验证标准差也能够在准确性和稳定性间达到平衡，被确定为最优模型，为后续分析提供技术基础。图 5 为使用随机森林模型后预测价格与实际价格的散点图，可见随机森林模型能够较好地捕捉数据中的规律。由图 6 可知，残差随机且均匀分布在零线周围，进一步验证了模型的稳健性和可靠性。




图 5. 预测值与实际值散点图

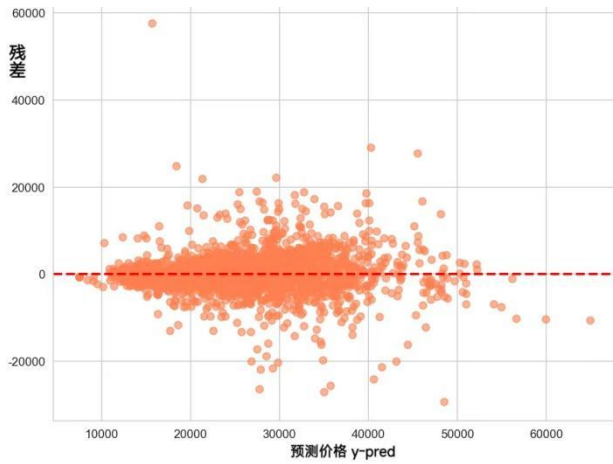


图 6. 残差分析

3.2 市场划分模型预测结果

由于预先不知北京房产市场的具体划分，因而首先尝试多种不同的聚类数量，绘制肘部图，如下图 7 所示：

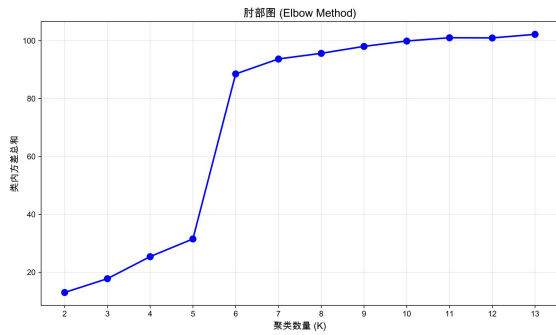


图 7. SKATER 聚类肘部图

当聚类类别为 6 时类内方差总和显著提升，之后效果提升并不明显，选择最终划分为 6 大市场。经归类后各大市场房产品如下图 8 所示：

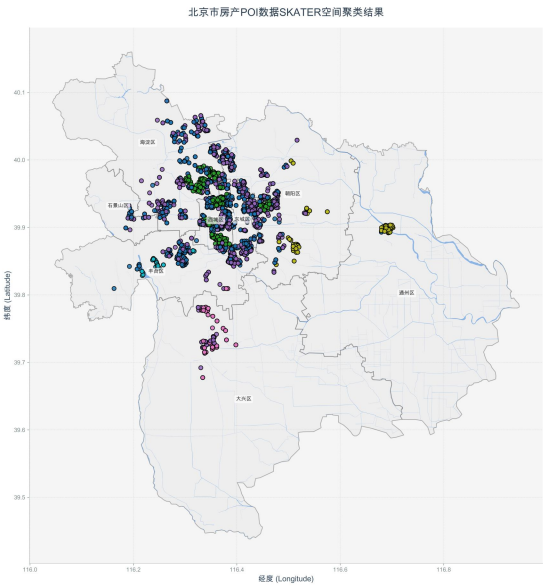


图 8. 北京房产空间聚类散点图

不同聚类点在空间上大致相互区别，形成了良好的空间分布特征。因而，本研究采用凸包方法粗略划分，形成最终的北京房产子市场划分。并且，探究各聚类集的主要价格因素特征及平均房产价格，如下图 9、表 9 所示：

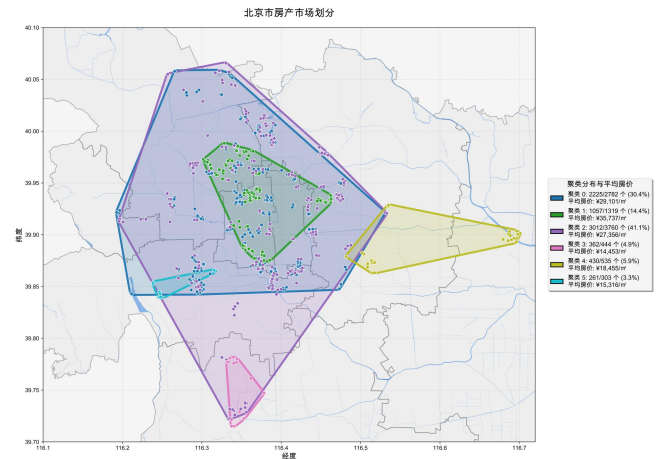


图 9. 北京市房价市场划分

表 9

各聚类因素主要影响因素及平均房产价格

标识符	主要影响因素	平均房产价格
0	医疗设施稀缺, 旅游景点丰富, 商业设施丰富	29,101
1	医疗设施丰富, 旅游景点丰富, 教育资源丰富	35,737
2	商业设施丰富, 建筑结构好, 旅游资源稀缺	27,356
3	商业设施稀缺, 医疗设	14,453

	施稀缺, 距离市中心远	
4	距离市中心远, 节点接近中心性低, 医疗设施稀缺	18,455
5	距离市中心远, 商业设施稀缺, 医疗设施稀缺	15,316

从空间上看, 各不同房产市场在范围上有所重合, 而在整体上则能够大致区分, 不难发现, 该类别聚集能够显著展示出中心城区, 边缘卫星城的房产市场区分。而从具体的影响因素看, 可以发现, 距离市中心的远近、附近是否具有医疗资源、附近商业资源是否丰富是影响房价市场的主要因素, 这与上文机器学习模型的模型结果趋于一致, 具有良好的区分性和现实意义。

4. 结论与讨论

4.1 主要结论

本研究基于 POI 数据提出了融合环境特征的房产价值预测与市场分类框架。研究以北京为例, 从建筑硬件、房屋属性和空间区位三个维度构建特征体系, 综合运用多种机器学习模型进行房价预测, 并结合网络分析与空间聚类方法划分城市房产市场。结果表明: (1) 基于树模型的集成学习方法在房价预测中表现优于传统线性模型, 其中随机森林模型的 R^2 达到 72.9%, 验证了构建特征体系的有效性; (2) 模型分析表明, 与空间区位相关的特征在模型中表现出较高的相关性和解释力, 说明房屋周边配套环境对房价具有重要影响; (3) 通过网络结构与空间聚类的综合分析, 中心城区的房价显著高于外围区域; 模型将北京市划分为六个子市场, 市场划分结果与医疗、商业、教育等高权重 POI 分布高度一致。结果表明功能聚集是影响城市房价分层的重要因素, 也说明 POI 特征在房产市场划分中具有较强的解释力。

4.2 理论贡献与实践启示

理论层面上, 本研究将 POI 显著性指标引入房产预测模型, 拓展了传统房价预测的范式, 为房产价值预测提供了新的解释路径; 同时, 采用系列机器学习模型对比分析, 进一步揭示非线性方法在处理复杂问题中的优势; 结合网络分析与空间聚类, 在房产价值预测的基础上构建市场划分的框架, 为理解城市房价的空间差异提供的新的视角。该方法框架与有一定的可扩展性。

实践层面, 本研究结果对城市规划与房产决策具有重要启示意义。政府可以根据 POI 特征认识城市功能的优势和挑战, 发挥更精准的宏观导向作用; 房地产企业可以利

用该框架科学评估房产潜力, 从而提高决策水平; 消费者可以根据 POI 显著性指标分析房产价值, 科学理性购房。总而言之, 该研究为多各主体提供了有价值的量化依据。

4.3 不足与展望

尽管本研究在融合 POI 特征的房产价值预测与房产市场划分方面取得了一定的积极成果, 但也存在不足之处。首先, 数据时效性有限, 本文仅采用 2011-2012 年的月交易数据, 无法精准反映近年来背景房产市场的最新变化; 其次, 在指标计算过程中, 仍结合了人工赋予先验权重, 具有一定的合理性, 但也存在着一定的主观性; 然后, 为保全模型的性能, 没有完全排除面积特征的影响, 具有信息泄露的风险; 最后, 研究以北京为例, 具有地域局限性。

未来研究可从以下方面改进: 引入最新多时段、多城市交易数据提高模型的时效性和泛化能力; 使用更适合的数据驱动方法全自动确定权重, 降低人为偏差; 优化特征设计, 使用更严格的特征选择方法以及隐私保护措施来增强模型的稳健性。

参考文献

- [1] 中国共产党新闻网. (2025 年 10 月 24 日). 中共二十届四中全会在京举行. 人民网—人民日报.
<http://www.cpcnews.cn>
- [2] Zhao, Y., Zhao, J., & Lam, E. Y. (2024). House price prediction: A multi-source data fusion perspective. *Big Data Mining and Analytics*, 7(3), 603-620.
- [3] Tang, J., Liu, Z., Wang, Y., Yang, J., & Wang, Q. (2018, September). Using geographic information and point of interest to estimate missing second-hand housing price of residential area in urban space. In *2018 IEEE International Smart Cities Conference (ISC2)* (pp. 1-8). IEEE.
- [4] Liu, X., Guo, R., Lei, G., & Liu, N. (2022). Classification of Housing Submarkets considering Human Preference: A Case Study in Shenyang, China. *Mathematical Problems in Engineering*, 2022(1), 2948352.
- [5] Shen, H., Li, L., Zhu, H., & Li, F. (2022). A pricing model for urban rental housing based on convolutional neural networks and spatial density: a case study of wuhan, china. *ISPRS International Journal of Geo-Information*, 11(1), 53.
- [6] 李贤增.(2019).基于多元回归分析和支持向量机的房价预测(硕士学位论文,清华大学).硕士
<https://doi.org/10.27266/d.cnki.gqhau.2019.000594>.
- [7] 谷秀娟 & 李超.(2012).基于马尔科夫链的房价预测研究.消费经济,28(05),40-42+48.
- [8] 唐晓彬,张瑞 & 刘立新.(2018).基于蝙蝠算法 SVR 模型的北京市二手房房价预测研究.统计研究,35(11),71-81.<https://doi.org/10.19343/j.cnki.11-1302/c.2018.11.006>.
- [9] 秦艳姣.(2024).基于多元线性回归与随机森林算法的房价预测模型对比研究.现代信息科技,8(22),127-131.<https://doi.org/10.19850/j.cnki.2096-4706.2024.22.025>.
- [10] Singh, A., & Chaudhary, C. (2022). House prices using machine learning algorithms. In *Proceedings of the 5th International Conference on Modern Engineering, Technology and Entrepreneurship (ICMETE 2021)* (pp. 747-758). Springer Nature Singapore.

附件

github 仓库链接:
可视化仪表盘: